STROKE PREDICTION

פרוייקט כריית מידע

Simcha Bar Shalom

שאלה 1:
סעיף א:

נבחר באלגוריתם חוקי הקשר Apriori.

Apriori הינו אלגוריתם איטרטיבי היוצר קבוצת מועמדים בגודל K מתוך קבוצת שכיחויות בגודל K-1. הוא גם מוצא קבוצת שכיחויות בגודל K מתוך קבוצת המועמדים בגודל K. תנאי העצירה הוא שאין יותר יצירת קבוצות מועמדים חדשות.
שלבי כריית קבוצת פריטים שכיחה:

- למצוא פריט שכיח אחד-אחד על ידי סריקה של בסיס הנתונים והסרת כל הפריטים שלא עוברים את סף הדרישה של מינימום תמיכה.
- מתבצע שלב הצירוף של שתי קבוצות שנמצאו בשלב הקודם כדי למצוא K קבוצות חדשות.
- בשלב הגיזום מסירים חלק מקבוצת K המועמדים אשר לא עומדים בתכונת האפריורי. יש סריקה נוספת על בסיס הנתונים בכדי לקבוע מספר התנועות שבהם הקבוצות מופיעות ושוב לבדוק האם הם עומדים בסף הדרישה של מינימום תמיכה כדי להכריע שקבוצות המועמדים באמת שכיחות.
- שלב 2 ו-3 חוזרים באופן איטרטיבי עד שאין יצירת קבוצת מועמדים חדשה.

ראינו שהטכניקה של האלגוריתם זה להשתמש בתכונה אפריורית וצירוף בשביל כריית הקבוצות השכיחות. האלגוריתם מבצע חיפוש לרוחב ודורש נפח אחסון גדול מאחר ובשלב ה-1, קבוצת המועמדים היא מאוד גדולה, הגורר גם סריקות מרובות לשם יצירת קבוצות המועמדים אשר משפיע על זמן הריצה שיותר מתבזבז על היצירה הקבוצות בכל פעם.
ונבחר באלגוריתם זה כי זהו אלגוריתם המתאם לבסיסי נתונים גדולים והינו אלגוריתם המתאפיין בפשטות ובהירות שעוזר להבנה.

פסאודו – קוד:

```
Apriori(T, ε)
    L1 ← {large singleton items}
    k ← 2
    while Lk-1 is not empty
        Ck ← Generate_candidates(Lk-1, k)
        for transactions t in T
            Dt ← {c in Ck : c ⊆ t}
            for candidates c in Dt
                count[c] ← count[c] + 1

        Lk ← {c in Ck : count[c] ≥ ε}
        k ← k + 1

    return Union(Lk) over all k

Generate_candidates(L, k)
    result ← empty_set()
    for all p ∈ L, q ∈ L where p and q differ in exactly one element
        c ← p ∪ q
        if u ∈ L for all u ⊆ c where |u| = k-1
            result.add(c)
  return result
```

סעיפים ב,ג,ד:

(עונה על שלושת הסעיפים יחד כי כל אחד מתחבר עם השני ורואה לנכון כך להציג תתשובה:)

נעבוד עם סט הנתונים המטוייב במטלה 21, סט הנתונים הינו לאחר טיפול בערכים חסרים / חריגים / כמפורט במטלה 21.
נתון Min_confidence = 60% וגם Min_support =40%, כלומר רק רשומות בעלות שכיחות גבוהה או שווה ל40% יופיעו בקבוצות תדירות בפלט האלגוריתם. (בנתונים שלנו ישנם 5109 רשומות ולכן כל מי שלפחות 2043 ומעלה יופיע בקבוצות התדירות).
נבצע דיסקרטיזציה, דיסקרטיזציה הינו אלגוריתם המסנן מופעים המפריד טווח של מאפיינים מספריים במערך הנתונים למאפיינים נומינליים. נגדיר את הגדרות האלגוריתם כך שחלוקת הסלים תהיה 2 זאת כדי שיהיה חלוקה טובה בהתאם ל Min_support הנתון.
להלן ההגדרות לבסיס הנתונים:

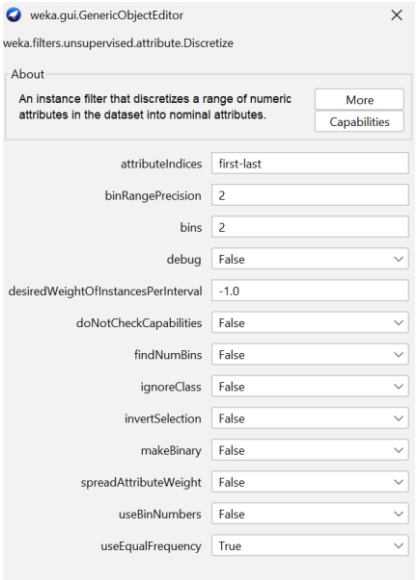

בנוסף נבצע Numerictonominal , Numerictonominal הינו אלגוריתם מסנן שממיר תכונה מספריות לתכונות נומינליות, כאשר הערכים המספריים מייצגים קטגוריות ולא ערכים כמותיים, כדי לבצע עיבוד נכון לפי אלגוריתמים למודל.

הרצת אלגוריתם אפריורי:

הרצנו את האלגוריתם עם 400 חוקי הקשר.

להלן הגדרות להרצת האלגוריתם עפ"י ההנחות:

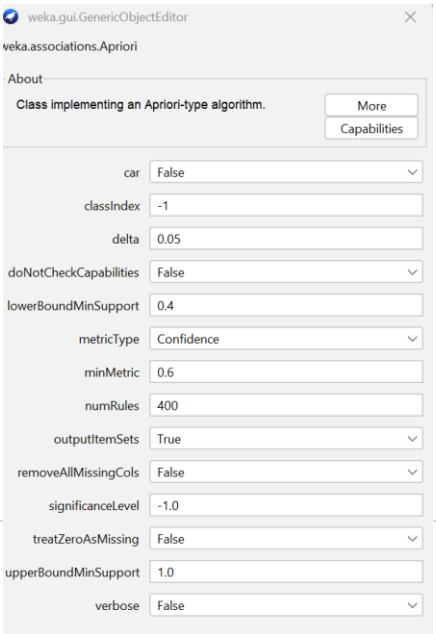

להלן פלט ההרצה של האלגוריתם:

=== Run information ===
Scheme: weka.associations.Apriori -I -N 500 -T 0 -C 0.6 -D 0.05 -U 1.0 -M 0.4 -S -1.0 -c -1
Relation: healthcare-dataset-stroke-data- maman-weka.filters.unsupervised.attribute.Discretize-F-B2-M-1.0-Rfirst-last-precision0-weka.filters.unsupervised.attribute.NumericToNominal-Rfirst-last
Instances: 5109
Attributes: 13
gender
age
hypertension
heart_disease
ever_married
work_type
Residence_type
avg_glucose_level
bmi
formerly smoked
never smoked
smokes
stroke
=== Associator model (full training set) ===
Apriori
=======
*Minimum support: **0.4** (2044 instances)*
*Minimum metric <confidence>: **0.6***

להלן הקבוצות התדירות שהתקבלו בפלט:

- **קבוצות תדירות בגודל 1:**

Size of set of large itemsets L(1).txt

- **קבוצות תדירות בגודל 2:**

Size of set of large itemsets L(2).txt

- **קבוצות תדירות בגודל 3:**

Size of set of large itemsets L(3).txt

- **קבוצות תדירות בגודל 4:**

Size of set of large itemsets L(4).txt

- **קבוצות תדירות בגודל 5:**

Size of set of large itemsets L(5).txt

בנוסף יש בפלט ההרצה את חוקי ההקשר החזקים כלומר אלו שעומדים בתנאים שהגדרנו לפי הנתונים.
קיבלנו **500 חוקי קשר חזקים** כך שכל אחד מהם עונה על הדרישות מתוך כך שהוא שהוא מעלה את ההסתברות ל – stroke.
להלן חוקי הקשר החזקים בפלט:

Best rules found.txt

נציג עשרה קשרים מתוך 500 הקשרים החזקים:
הניתוח מתבסס על המדדים המוצגים בפלט:
confidence, lift

78. hypertension='(-inf-1]' avg_glucose_level='(-inf-92]' stroke=0 2300 ==> heart_disease='(-inf-1]' 2233 <conf:(0.97)> lift:(1.03) lev:(0.01) [57] conv:(1.83)
79. heart_disease='(-inf-1]' formerly smoked='(-inf-1]' never smoked='(-inf-1]' 2224 ==> stroke=0 2158 <conf:(0.97)> lift:(1.02) lev:(0.01) [42] conv:(1.62)
80. gender=Female smokes='(-inf-1]' stroke=0 2420 ==> heart_disease='(-inf-1]' 2348 <conf:(0.97)> lift:(1.03) lev:(0.01) [58] conv:(1.79)
81. gender=Female formerly smoked='(-inf-1]' stroke=0 2410 ==> heart_disease='(-inf-1]' 2338 <conf:(0.97)> lift:(1.03) lev:(0.01) [58] conv:(1.78)
82. heart_disease='(-inf-1]' bmi='(-inf-28]' 2441 ==> stroke=0 2368 <conf:(0.97)> lift:(1.02) lev:(0.01) [45] conv:(1.61)
83. bmi='(-inf-28]' formerly smoked='(-inf-1]' 2205 ==> stroke=0 2139 <conf:(0.97)> lift:(1.02) lev:(0.01) [41] conv:(1.6)
84. hypertension='(-inf-1]' formerly smoked='(-inf-1]' smokes='(-inf-1]' stroke=0 3051 ==> heart_disease='(-inf-1]' 2957 <conf:(0.97)> lift:(1.02) lev:(0.01) [70] conv:(1.73)
85. hypertension='(-inf-1]' avg_glucose_level='(-inf-92]' 2366 ==> heart_disease='(-inf-1]' 2293 <conf:(0.97)> lift:(1.02) lev:(0.01) [54] conv:(1.73)
86. gender=Female hypertension='(-inf-1]' heart_disease='(-inf-1]' formerly smoked='(-inf-1]' 2235 ==> stroke=0 2166 <conf:(0.97)> lift:(1.02) lev:(0.01) [39] conv:(1.56)
87. gender=Female hypertension='(-inf-1]' 2718 ==> heart_disease='(-inf-1]' 2634 <conf:(0.97)> lift:(1.02) lev:(0.01) [62] conv:(1.73)
88. hypertension='(-inf-1]' heart_disease='(-inf-1]' Residence_type=Rural 2161 ==> stroke=0 2094 <conf:(0.97)> lift:(1.02) lev:(0.01) [38] conv:(1.55)

נראה כי הנתונים די זהים בערכים , זוהי הייתי הרצה ללא סיווג כלשהוא על עמודה אלא כללי , לכן נבצע שוב הרצה אבל הפעם להתייחסות ל stroke עמודת המטרה.

להלן הגדרות להרצת האלגוריתם עפ"י ההנחות:

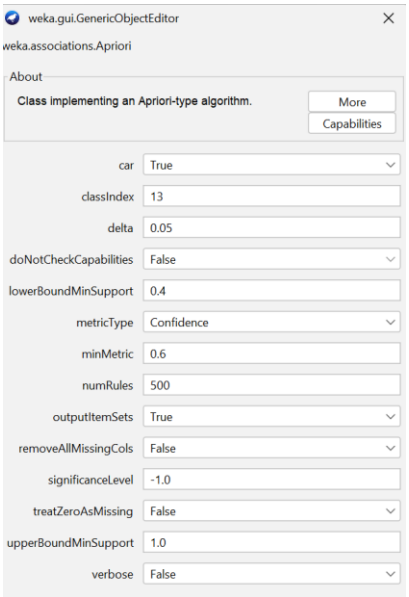

להלן פלט ההרצה של האלגוריתם:

```
=== Run information ===
Scheme:     weka.associations.Apriori -I -N 500 -T 0 -C 0.6 -D 0.05 -U 1.0 -M 0.4 -S -1.0 -A -c 13
Relation:    healthcare-dataset-stroke-data- maman-weka.filters.unsupervised.attribute.Discretize-F-B2-M-1.0-Rfirst-last-precision0-weka.filters.unsupervised.attribute.NumericToNominal-Rfirst-last
Instances:   5109
Attributes:  13
          gender
          age
          hypertension
          heart_disease
          ever_married
          work_type
          Residence_type
          avg_glucose_level
          bmi
          formerly smoked
          never smoked
          smokes
          stroke
=== Associator model (full training set) ===
Apriori
=======
Minimum support: 0.4 (2044 instances)
Minimum metric <confidence>: 0.6
```

להלן הקבוצות התדירות שהתקבלו בפלט:

- **קבוצות תדירות בגודל 1:**

Size of set of large itemsets L(1).txt

- **קבוצות תדירות בגודל 2:**

Size of set of large itemsets L(2).txt

- **קבוצות תדירות בגודל 3:**

Size of set of large itemsets L(3).txt

- **קבוצות תדירות בגודל 4:**

Size of set of large itemsets L(4).txt

בנוסף יש בפלט ההרצה את חוקי ההקשר החזקים כלומר אלו שעומדים בתנאים שהגדרנו לפי הנתונים.
קיבלנו **107 חוקי קשר חזקים** כך שכל אחד מהם עונה על הדרישות מתוך כך שהוא שהוא מעלה את ההסתברות ל – stroke.
להלן חוקי הקשר החזקים בפלט:

Best rules found.txt

נציג עשרה קשרים מתוך 500 הקשרים החזקים:
הניתוח מתבסס על המדדים המוצגים בפלט:
confidence, lift

age='(-inf-45]' heart_disease='(-inf-1]' formerly smoked='(-inf-1]' 2286 ==> stroke=0 2278 (conf:(1

(age='(-inf-45]' hypertension='(-inf-1]' 2476 ==> stroke=0 2467 conf:(1

age='(-inf-45]' hypertension='(-inf-1]' heart_disease='(-inf-1]' 2470 ==> stroke=0 2461 (conf:(1

(age='(-inf-45]' 2532 ==> stroke=0 2522 conf:(1

(age='(-inf-45]' heart_disease='(-inf-1]' 2525 ==> stroke=0 2515 conf:(1

hypertension='(-inf-1]' heart_disease='(-inf-1]' bmi='(-inf-28]' 2328 ==> stroke=0 2277 (conf:(0.98

hypertension='(-inf-1]' bmi='(-inf-28]' formerly smoked='(-inf-1]' 2104 ==> stroke=0 2055 (conf:(0.98

hypertension='(-inf-1]' bmi='(-inf-28]' smokes='(-inf-1]' 2112 ==> stroke=0 2062 (conf:(0.98

heart_disease='(-inf-1]' bmi='(-inf-28]' formerly smoked='(-inf-1]' 2135 ==> stroke=0 (2080 conf:(0.97

(hypertension='(-inf-1]' bmi='(-inf-28]' 2403 ==> stroke=0 2341 conf:(0.97

hypertension='(-inf-1]' heart_disease='(-inf-1]' avg_glucose_level='(-inf-92]' 2293 ==> (stroke=0 2233 conf:(0.97

ניתן לראות שהתוצאה תלויה בעיקר במשתנה ,Stroke אך קיימת בעיה של חוסר איזון בעמודה – בכך שרואים שכל הערכים הם 0, מצב כזה יוצר שאלה – האם להשאיר את חוסר האיזון כמו שהוא, או לנסות לאזן את הנתונים כדי לשפר את הדיוק של המודל?
אז בכדי להריץ את אלגוריתם Apriori עם התמקדות בסיווג של Stroke ולמנוע את השפעת חוסר האיזון בנתונים, אפשר לבחור להתמקד רק ברשומות שבהן הערך של Stroke הוא 1. כלומר, נסיר את כל השורות שבהן Stroke שווה ל-0. נבצע את הצעד הזה אך ורק לצורך מציאת קבוצות תדירות וחוקי קישור משמעותיים.
נתון Min_confidence = 60% וגם Min_support =40%, כלומר רק רשומות בעלות שכיחות גבוהה או שווה ל40% יופיעו בקבוצות תדירות בפלט האלגוריתם. (בנתונים שלנו
ישנם 249 רשומות ולכן כל מי שלפחות 100 ומעלה יופיע בקבוצות התדירות).
נבצע על הנתונים כפי שבצענו בהתחלה.

הרצת אלגוריתם אפריורי:

הרצנו את האלגוריתם כפי שהגדרנו בהרצה הקודמת.
להלן פלט ההרצה של האלגוריתם:

```
=== Run information ===
Scheme:     weka.associations.Apriori -I -N 400 -T 0 -C 0.6 -D 0.05 -U 1.0 -M 0.4 -S -1.0 -A -c 13
Relation:   healthcare-dataset-stroke-data- maman-weka.filters.unsupervised.attribute.Discretize-B2-M-1.0-Rfirst-last-precision6-weka.filters.unsupervised.attribute.Discretize-F-B2-M-1.0-Rfirst-last-precision2-weka.filters.unsupervised.attribute.Discretize-F-B2-M-1.0-Rfirst-last-precision2-weka.filters.unsupervised.attribute.NumericToNominal-Rfirst-last-weka.filters.unsupervised.attribute.NumericToNominal-Rfirst-last
Instances:   249
Attributes:  13
             gender
             age
             hypertension
             heart_disease
             ever_married
             work_type
             Residence_type
             avg_glucose_level
             bmi
             formerly smoked
             never smoked
```

```
        smokes
        stroke
=== Associator model (full training set) ===
Apriori
=======
Minimum support: 0.4 (100 instances)
Minimum metric <confidence>: 0.6
Number of cycles performed: 12
```

להלן הקבוצות התדירות שהתקבלו בפלט:

- **קבוצות תדירות בגודל 1:**

  Size of set of large itemsets L(1).txt

- **קבוצות תדירות בגודל 2:**

  Size of set of large itemsets L(2).txt

- **קבוצות תדירות בגודל 3:**

  Size of set of large itemsets L(3).txt

- **קבוצות תדירות בגודל 4:**

  Size of set of large itemsets L(4).txt

- **קבוצות תדירות בגודל 5:**

  Size of set of large itemsets L(5).txt

בנוסף יש בפלט ההרצה את חוקי ההקשר החזקים כלומר אלו שעומדים בתנאים שהגדרנו לפי הנתונים.
קיבלנו **246 חוקי קשר חזקים** כך שכל אחד מהם עונה על הדרישות מתוך כך שהוא שהוא מעלה את ההסתברות ל – stroke.

להלן חוקי הקשר החזקים בפלט:

Best rules found.txt

לסיכום מההרצות השונות:
במהלך ביצוע הניתוח בוצעו שלוש הרצות שונות במטרה לבחון את השפעת משתנה על הstroke.

- בהרצה הראשונה שכללה את כלל הנתונים ללא סיווג, והציגה תוצאות כלליות אך פחות ממוקדות.

נפרט מסקנות:

  - בהרצה זו הופקו כ-500 חוקים, מה שהוביל לכמות גדולה של קבוצות תדירות וחוקי קשר. עם זאת, לא כל החוקים שהתקבלו בהכרח משמעותיים, שכן לא הייתה כאן התמקדות בסיווג או במטרה מוגדרת.
  - החוקיות שיצאה מההרצה הזו היא כללית, בלי קשר לעמודה מסוימת. לא בדקנו כאן השפעה של משתנה אחד על אחר, ולכן התוצאות לא הראו על משהו מסוים.
  - היתרון הוא שהחוקים שהתקבלו הם אובייקטיביים – הם משקפים קשרים שקיימים בנתונים עצמם, בלי להיות מושפעים מסיווג או מטרה ספציפית.
  - מצד שני, החיסרון הוא שהחוקים האלה לא עוזרים לנו להבין תופעה מסוימת, כמו למשל מתי עלול להתרחש שבץ (stroke) ומתי לא. לכן, הם פחות שימושיים כשאנחנו רוצים לבנות מודל שמבוסס על סיווג או חיזוי.

- בהרצה השנייה נוסף סיווג לפי stroke דבר שיצר בעיית חוסר איזון – מרבית הרשומות היו עם ערך 0, מה שהשפיע על איכות התוצאות.

נפרט מסקנות:

  - בהרצה הזו השתמשתי ב stroke-כעמודת סיווג, כלומר זו הייתה עמודת היעד שלפיה האלגוריתם ניסה לזהות דפוסים.
  - התוצאה הייתה שכל החוקים התבססו כמעט רק על מקרים שבהם stroke=0, בגלל חוסר איזון בנתונים.
  - בהרצה ניתן לראות כי התקבלו חוקים "חזקים" מבחינה חישובית, אבל בפועל הם לא באמת תורמים – כי הם מתארים רק את הקבוצה הגדולה, כלומר את מי שלא חווה שבץ.
  - מהנקודה האחרונה ומהסתכלות בפלט נראה כי הופיע המצב ש stroke=0 ולכן זה לא עוזר לנו לזהות את המקרה של סיכון לשבץ – stroke=1.

- בהרצה השלישית נבחרו רק הרשומות בהן stroke=1, במטרה להתמקד במקרים הרלוונטיים בלבד. גישה זו הובילה לתוצאות ברורות יותר, אך ללא חישוב ערך ה Lift-, מה שמעורר התלבטות לגבי אופן ההצגה המועדף.

נפרט מסקנות:

  - בהרצה הזו עבדתי רק עם הנתונים שבהם הערך של stroke הוא 1, כלומר סיננתי מראש את כלל המקרים של שבץ – מה שהשאיר רק 249 רשומות.
  - בגלל הסינון התקבלו חוקי קשר ממוקדים ומדויקים יותר, ומתארים את אנשים שחוו שבץ ואז מאפשר להבין טוב יותר מה המאפיינים שגמרו לשבץ.
  - ישנו יתרון בולט בגישה הזו כי נוצרו חוקים רלוונטים בדיוק למה שמעניין אותי לחזות כלומר מתמקד רק באנשים עם שבץ.
  - ישנו חסרון משמעותי בשיטה הזו כי יש כמות נתונים קטן יחסית.

ולכן עולה לי השאלה עד כמה המסקנות האלו מייצגות את כלל האוכלוסייה מבחינה סטטיסטית.

סעיף ה:

סיכום ומסקנות:

במהלך העבודה בצענו שלוש הרצות שונות, כאשר כל אחת מהן הציעה גישה שונה לניתוח הנתונים. בכל הרצה היה דגשים והיבטים אחרים של הקשרים בין המשתנים, והציפה יתרונות מסוימים לצד מגבלות ברורות. ההרצה הראשונה הייתה רחבה וכללית, אך חסרה מיקוד בהקשר של שבץ. השנייה ניסתה להתמקד בכך, אך נתקלנו בבעיית חוסר איזון משמעותית. השלישית אומנם כללה רק את מקרי השבץ עצמם, אך הצליחה לייצר תובנות ממוקדות ורלוונטיות.

מכך נסיק:

למרות שההרצה השלישית התבצעה על כמות קטנה יחסית של נתונים, היא הכי מתאימה למטרה של הפרויקט – להבין מה מאפיין אנשים שלקו בשבץ. הגישה הזו מאפשרת לנו להתמקד בדיוק בקבוצה שמעניינת אותנו, ולזהות את הקשרים הכי חשובים ורלוונטיים. לכן, מבין שלוש ההרצות, זו ההרצה שנותנת את התשובות הכי טובות לשאלת המחקר, ועוזרת לנו להתקדם בצורה ממוקדת לבניית מודל שינסה לחזות סיכון לשבץ.

שאלה 2:
סעיף א:

מדדי איכות האשכול איכות תהליך האשכול תלויה במספר גורמים, כגון סוג מדד הדמיון שבו נעשה שימוש (כמו מרחק אוקלידי או מרחק מנהטן), ההגדרות והפרמטרים שנבחרו עבור שיטת האשכול, אופן היישום שלה, והדרך שבה היא הופעלה בפועל.

קיימים מספר מדדים להערכת איכות האשכולות:

- מדד לבחינת הדמיון בין פריטים בתוך אותו אשכול, לעומת מידת השוני בינם לבין פריטים מאשכולות אחרים. לרוב נעשה שימוש במדדי מרחק כגון אוקלידי או מנהטן.
- מדד שבודק עד כמה השיטה מצליחה לזהות תבניות נסתרות בקבוצת הנתונים – כלומר, לאתר קבוצות של פריטים שיש ביניהם קשר כלשהו, שלא היה ידוע מראש.
- מדדים שמבוססים על דמיון או שונות – כאשר הדמיון או השונות בין פריטים נמדדים לפי המרחק ביניהם, ויש לבחור פונקציית מרחק מתאימה בהתאם לסוג הנתונים (מספריים, קטגוריאליים, בוליאניים וכדומה).
- מדד כללי לאיכות האשכול, שבודק את רמת ההתאמה של הפלט באמצעות פונקציית הערכה נפרדת.

סעיף ב:

הגישה לניתוח אשכולות שנבחרת היא גישת האשכול K-means.
אלגוריתם K-means הינו אלגוריתם המחלק את הנתונים לאשכולות על בסיס נקודות מרכזיות (Centroids) שמייצגות את הממוצע של המיקומים של כל הפריטים המשתייכים לאותו אשכול.
האלגוריתם מקבל כקלט את K - מספר האשכולות הרצוי, יחד עם מערך הנתונים – כלומר את כלל העצמים שצריך לשייך לאשכולות.
פסאודו קוד:

Algorithm: k-means
The k-means algorithm for partitioning, where each cluster's center is represented by the mean value of the objects in the cluster.

Input:
k: the number of clusters
D: a data set containing n objects

Output: A set of k clusters

Method:
*(1) arbitrarily choose *k* objects from *D* as the initial cluster centers;*
(2) repeat
(3) (re)assign each object to the cluster to which the object is the most similar;
(4) update the cluster centers, that is, calculate the mean value of the objects for each cluster;
(5) until no change;

שלבי האלגוריתם – הסבר פסאודו קוד:

1. בוחרים באופן אקראי K עצמים מתוך קבוצת הנתונים שישמשו כמרכזים התחלתיים של האשכולות.
2. מבצעים לולאה שחוזרת על שני השלבים הבאים עד שלא מתרחשים שינויים בשיוך העצמים לאשכולות:
   2.1. כל עצם משויך לאשכול שאליו הוא הכי דומה – כלומר, לאשכול שהמרכז שלו הקרוב ביותר אליו.
   2.2. מעדכנים את מיקומי המרכזים של האשכולות על ידי חישוב הממוצע של כל העצמים באותו אשכול.

בחרתי להשתמש באלגוריתם K-Means בגלל יתרונותיו השונים, להלן היתרונות:

- המאגר מכיל יותר מ־5000 רשומות, ולכן חשוב לבחור באלגוריתם שיודע להתמודד עם כמות גדולה של נתונים בצורה יעילה האלגוריתם נחשב ליעיל במיוחד כי זמן הריצה שלו ליניארי ביחס לגודל הנתונים (O(n*k*t, כאשר n הוא מספר הדגימות, k הוא מספר האשכולות ו-t הוא מספר האיטרציות). זה מאפשר להריץ אותו גם על מאגרים גדולים בלי זמן חישוב ממושך.
- יתרון נוסף הוא ש־K-Means מתאים למצבים שבהם הנתונים ניתנים לחלוקה ברורה לקבוצות לפי קרבה מרחבית, וזה תואם את אופי הנתונים שלי. האלגוריתם יוצר אשכולות בצורה פשוטה ומובנת, מה שמקל על הסקת מסקנות והצגת התוצאות.
- היישום של האלגוריתם לא מסובך יחסית, וניתן להפעיל אותו בקלות באמצעות כלים סטנדרטיים, כך שהוא גם חסכוני בזמן פיתוח ולא רק בזמן ריצה.

סעיף ג:

נעבוד עם סט הנתונים המטוייב במטלה 21, סט הנתונים הינו לאחר טיפול בערכים חסרים / חריגים / כמפורט במטלה 21.
על סט הנתונים אלו נבצע תדברים הבאים:

- נבצע Normalization , Normalization הינו שיטת נרמול כך שהיא מביאה את כל ערכי התכונות להיות רציפות בטווח 1 – 0 וזאת כדי למנוע הטעיות שנובעות מהבדלי סדרי גודל בין עמודות שונות. שיטת הנרמול שומרת על יחס הנתונים בתהליך זה.
- נבצע NominalToBinary, NominalToBinary הינו אלגוריתם המעביר עמודות קטגוריות (nominal)לייצוג בינארי, כדי לאפשר לאלגוריתמים להבין ולעבד את המידע בצורה מספרית.
- נבצע Numerictonominal על עמודת ה stroke, Numerictonominal הינו אלגוריתם מסנן שממיר תכונה מספריות לתכונות נומינליות, כאשר הערכים המספריים מייצגים קטגוריות ולא ערכים כמותיים, כדי לבצע עיבוד נכון לפי אלגוריתמים למודל.
- נוסיף כהערה כאן לא נבצע דיסקרטיזציה, כיוון שהאלגוריתם K-Means משתמש במרחק אוקלידי ודורש נתונים רציפים. המרה לערכים בדידים עלולה לפגוע בדיוק החישוב ולהוביל לאשכולות לא מדויקים.

לאחר ביצוע הדברים הנ"ל כל הנתונים מותאמים לעבודה עם אלגוריתם **k-means** המשתנים המספריים נורמלו לטווח של 0–1, העמודות הקטגוריות הומרו לייצוג מספרי מתאים, ועמודת הסיווג הוגדרה כנומינלית. כל אלו מאפשרים חישוב מדויק של מרחקים בין דגימות. מאחר והמשימה מתמקדת בהבחנה בין שתי קבוצות האם קיים שבץ או לא קיים שבץ – ואם כך נקבע חלוקה לk=2.

סעיף ד:

נריץ את האלגוריתם עם הגדרת ערכי הפרמטרים הבאים:

canopyMaxNumCanopiesToHoldInMemory	100
canopyMinimumCanopyDensity	2.0
canopyPeriodicPruningRate	10000
canopyT1	-1.25
canopyT2	-1.0
debug	False
displayStdDevs	False
distanceFunction	Choose **EuclideanDistance** -R first-last
doNotCheckCapabilities	False
dontReplaceMissingValues	False
fastDistanceCalc	False
initializationMethod	Random
maxIterations	500
numClusters	2
numExecutionSlots	1
preserveInstancesOrder	False
reduceNumberOfDistanceCalcsViaCanopies	False
seed	10

ונקבל כי תוצאות ההרצה הם:

```
Ignored:
        stroke
Test mode:    Classes to clusters evaluation on training data
=== Clustering model (full training set) ===
kMeans
======
Number of iterations: 7
Within cluster sum of squared errors: 9353.060934912412
Initial starting points (random):
Cluster 0: 0,0.780273,0,0,0,0,1,0,0,0,1,0.714985,0.233677,1,0,0
Cluster 1: 1,0.414063,0,0,0,1,0,0,0,0,0,0.165728,0.177549,0,1,0
Missing values globally replaced with mean/mode
Final cluster centroids:
                        Cluster#
Attribute               Full Data        0        1
                      (5109.0)   (1476.0)   (3633.0)
==========================================================
gender=Female            0.586     0.6118     0.5756
age                      0.5267    0.6833     0.4631
hypertension             0.0975    0.147      0.0773
heart_disease            0.054     0.0793     0.0438
ever_married=No          0.3437    0.1538     0.4209
work_type=Private        0.5723    0          0.8048
work_type=Self-employed  0.1603    0.5549     0
work_type=Govt_job       0.1286    0.4451     0
```

work_type=children	0.1345	0	0.1891
work_type=Never_worked	0.0043	0	0.0061
Residence_type=Rural	0.4919	0.4776	0.4977
avg_glucose_level	0.2355	0.2556	0.2274
bmi	0.213	0.2289	0.2065
formerly smoked	0.173	0.231	0.1495
never smoked	0.3703	0.4153	0.3521
smokes	0.1544	0.1653	0.15

Time taken to build model (full training data) : 0.02 seconds

=== Model and evaluation on training set ===

Clustered Instances

0 1476 (29%)
1 3633 (71%)

Class attribute: stroke

Classes to Clusters:

0	1	<-- assigned to cluster
1378	3482	0
98	151	1

Cluster 0 <-- 1

Cluster 1 <-- 0

Incorrectly clustered instances : 1529.0 **29.9276 %**

ננתח את תוצאות הפלט:

- קיבלנו כי יש 7 איטרציות.
- בהפעלת האלגוריתם עם k=2 על מאגר הנתונים מסעיף ג', ערך שגיאת הריבועים המצטברת עומד על 9353.0609.
- בניתוח התוצאות נראה כי האלגוריתם ביצע חלוקה מדויקת ומוצלחת של הנתונים לשני אשכולות מובחנים: אשכול 0, המכיל 1476 דגימות (29%), ואשכול 1, המכיל 3633 דגימות (71%).
  התוצאות מוכיחות זיהוי חד-משמעי של פרופיל סיכון גבוה באשכול 0, המאופיין באוכלוסייה מבוגרת עם מחלות רקע, והבדלתו המוצלחת מהאוכלוסייה הכללית באשכול 1.
- שיעור השגיאה (29.93%) אינו מעיד על כישלון, אלא חושף את מורכבות הבעיה ואת החפיפה הטבעית בין הקבוצות – תובנה שהמודל הצליח ברובו לעבור בהצלחה.

הצגת פלט בגרף:

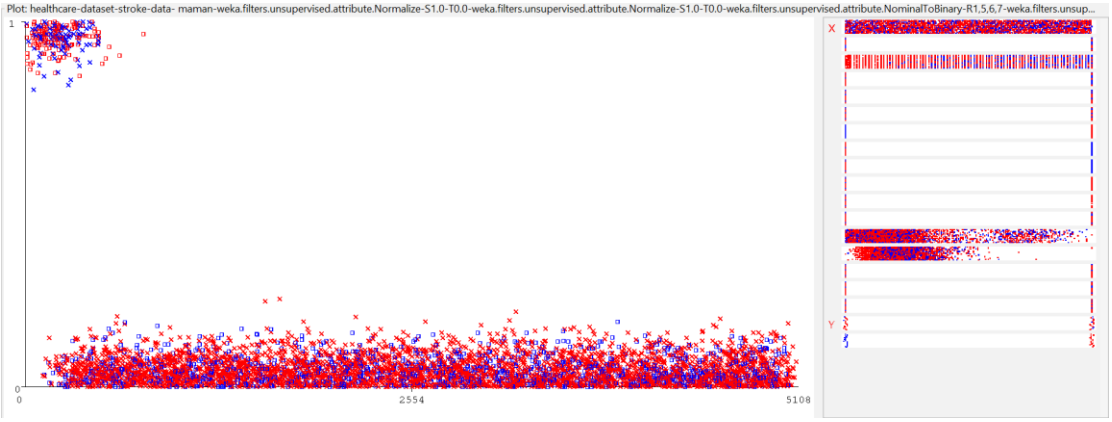

ניתן לראות כי הניתוח הוויזואלי מציג תוצאה חיובית ביותר, המדגימה את יכולתו של המודל גם לזהות קבוצת סיכון גבוהה ומבודדת, וגם להמחיש את מורכבות הבעיה עם מקרים המפוזרים באוכלוסייה הכללית.

סעיף ה:

ניתוח תוצאות הרצת אלגוריתם k-Means מוביל למסקנות ברורות לגבי איכות המודל והתובנות שהופקו:

- האלגוריתם הצליח לחשוף בהצלחה קבוצת סיכון מובהקת (אשכול 0, 29% מהנתונים), המאופיינת בגיל גבוה ומחלות רקע. יכולת זו לזהות פרופיל סיכון ברור מהווה אינדיקציה חזקה לאיכות הניתוח.
- הוכח כי k-Means הוא כלי יעיל לאפיון קבוצות ולגילוי תבניות, אך אינו אלגוריתם סיווג מדויק. הוא מזהה את *הפרופיל* של קבוצת הסיכון, אך לא מבודד באופן נקי את כל מקרי השבץ.
- שיעור השגיאה (29.93%) אינו מעיד על כישלון, אלא חושף תובנה חשובה: קיימת חפיפה משמעותית בין מאפייני האוכלוסיות, והמודל הצליח להמחיש את מורכבות הבעיה בצורה טובה.
- התובנות שהתקבלו, ובפרט זיהוי המשתנים שתורמים להפרדה (גיל, מחלות רקע), מהוות בסיס איתן לבניית מודלים מפוקחים ומדויקים יותר להמשך.

שאלה 3:

סעיף א:

נבחרה לעבוד עם ארכיטקטורת רשת נוירונים מסוג Feedforward Neural Network (רשת הזנה קדמית). בארכיטקטורה זו, זרימת המידע היא חד-כיוונית בלבד: מהשכבת הקלט, דרך השכבות החבויות, ועד לשכבת הפלט, ללא חיבורים חוזרים לשכבות קודמות.

מבנה השכבות:

- **שכבת קלט -** מספר הנוירונים בשכבה זו נקבע לפי מספר התכונות בסט הנתונים. ברשת שנבחרה, שכבת הקלט כוללת 29 נוירונים.
- **שכבות חבויות -** הרשת מכילה שתי שכבות חבויות עם 16 ו-8 נוירונים בהתאמה. חשוב לציין כי אין נוסחה אחידה לקביעת מספר הנוירונים או השכבות החבויות, וזוהי לרוב תוצאה של אופטימיזציה ניסיונית. כל נוירון בשכבה אחת מחובר לכל הנוירונים בשכבה הבאה.
- **שכבת פלט -** מספר הנוירונים בשכבת הפלט תואם למספר הקטגוריות של משתנה המטרה. במקרה זה, שכבת הפלט מכילה 3 נוירונים.

פונקציות הפעלה:

פונקציות ההפעלה קובעות את הפלט של כל נוירון ומכניסות אי-ליניאריות למודל, המאפשרת לו ללמוד דפוסים מורכבים:

- פונקציית ברירת מחדל Sigmoid (Weka).
- פונקציות נפוצות נוספות :
  - ReLU (Rectified Linear Unit): פולטת 0 עבור קלטים שליליים ופלט ליניארי עבור קלטים חיוביים.
  - Softmax: משמשת בעיקר בשכבת הפלט עבור בעיות סיווג רב-מחלקה (יותר משתי קטגוריות), ומספקת הסתברות עבור כל קטגוריה.

סעיף ב:

בתהליך האימון של רשתות עצביות, אופטימיזציה היא השלב שבו המודל לומד לכוונן את עצמו במטרה להגיע לביצועים הטובים ביותר. חלק בלתי נפרד מאופטימיזציה זו הוא הבחירה וההגדרה של מספר פרמטרים קריטיים. פרמטרים אלו משפיעים ישירות על תהליך הלמידה ועל איכות התוצאה הסופית. שלושת הפרמטרים המרכזיים שנדון בהם הם: גודל האצווה (Batch Size), פונקציית השגיאה (Loss Function) וקצב הלמידה (Learning Rate).

גודל Batch Size:

גודל האצווה מגדיר כמה דוגמאות אימון מעובדות יחד לפני שמשקלי הרשת מתעדכנים.

- Batch Size קטנה - מביאה ליותר עדכוני משקלים לכל תקופת אימון (epoch). זה יכול להוביל ללמידה פחות יציבה אך לעיתים קרובות מאפשר למצוא פתרונות מדויקים יותר.
- Batch Size גדולה - פירושה פחות עדכונים, מה שיכול לשפר את יציבות הלמידה ומהירות ההתכנסות, אך עלול לגרום למודל "לפספס" נקודות אופטימליות במרחב הפתרונות.

לדוגמה, עם 5,000 דוגמאות אימון וגודל אצווה של 100, יתבצעו 50 עדכונים קבוצתיים בכל תקופה (5000/100). ב-Weka, גודל אצווה ברירת המחדל הוא בדרך כלל 100. לגודל האצווה השפעה ניכרת על יציבות הלמידה, מהירות ההתכנסות ודיוק המודל הסופי.

פונקציית השגיאה (Loss Function)

פונקציית השגיאה, הידועה גם כפונקציית הפסדים, משמשת למדידת ההבדל בין התוצאה שהמודל חוזה לבין התוצאה האמיתית. מטרת האלגוריתם היא למזער את ערכה של פונקציה זו ככל האפשר במהלך האימון.
דוגמה נפוצה היא השגיאה הריבועית הממוצעת (MSE - Mean Squared Error), המחשבת את ממוצע ריבועי ההבדלים בין התחזית למציאות. ככל שערך ה-MSE נמוך יותר, ביצועי המודל נחשבים טובים יותר.

קצב הלמידה (Learning Rate)

קצב הלמידה קובע את גודל ה"צעד" שבו משקלי הרשת מתעדכנים בכל איטרציה.

- קצב למידה גבוה - עשוי להוביל להתכנסות מהירה יותר, אך עלול לגרום למודל "לדלג" מעל פתרונות אופטימליים.
- קצב למידה נמוך - מקדם למידה איטית וזהירה יותר, ולעיתים קרובות מאפשר הגעה לפתרון מדויק יותר, אך דורש זמן ריצה ארוך יותר. ב-Weka, ערך ברירת המחדל לקצב הלמידה הוא 0.3.

לסיכום, בחירה נבונה של פרמטרים כמו גודל האצווה, קצב הלמידה וסוג פונקציית השגיאה היא חיונית להצלחת תהליך האופטימיזציה ואימון המודל. התאמה מדויקת של ערכים אלו יכולה להשפיע באופן משמעותי על מהירות ההתכנסות, יציבות הלמידה ורמת הדיוק הסופית של המודל. לכן, הבנה מעמיקה של משמעות כל פרמטר ובחירה בערכים המתאימים ביותר לאופי הבעיה הספציפית היא קריטית.

סעיף ג:

רשת הנוירונים שמתקבלת בצורה ויזואלית:

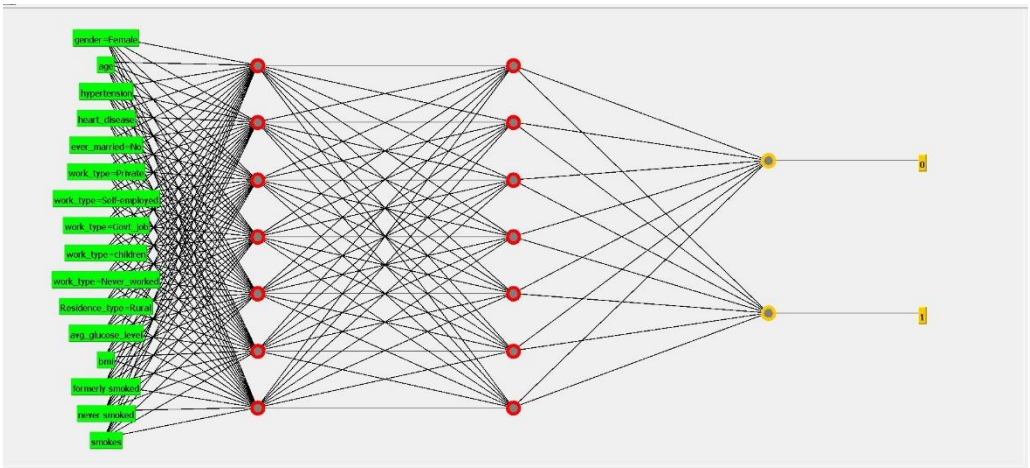

נציג את נתוני ההרצות על שגיאות מבחן ושגיאות אימון עם Epoch שאיתם נציג תגרפים.
הצגת הנתונים:

Epoch – Error Training	Epoch – Error Training	Epoch – Error Test	Epoch – Error Test
52,	0.0961632	51,	0.0932039
122,	0.092048	140,	0.0866196
184,	0.0907724	219,	0.0842376
245,	0.0897581	261,	0.0842188

0.082413 ,318	0.0893671 ,314
0.0839627 ,380	0.0894308 ,422
0.0832654 ,447	0.0868748 ,479
0.0832658 ,500	0.0869154 ,500

הגרף המייצג את Epoch – Error Training:

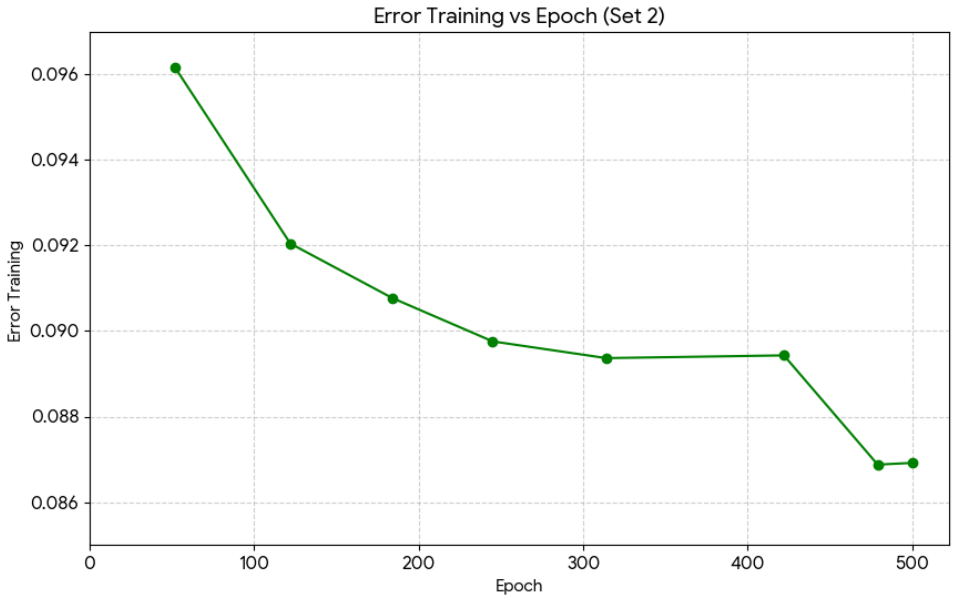

הגרף המייצג את Epoch – Error Test:

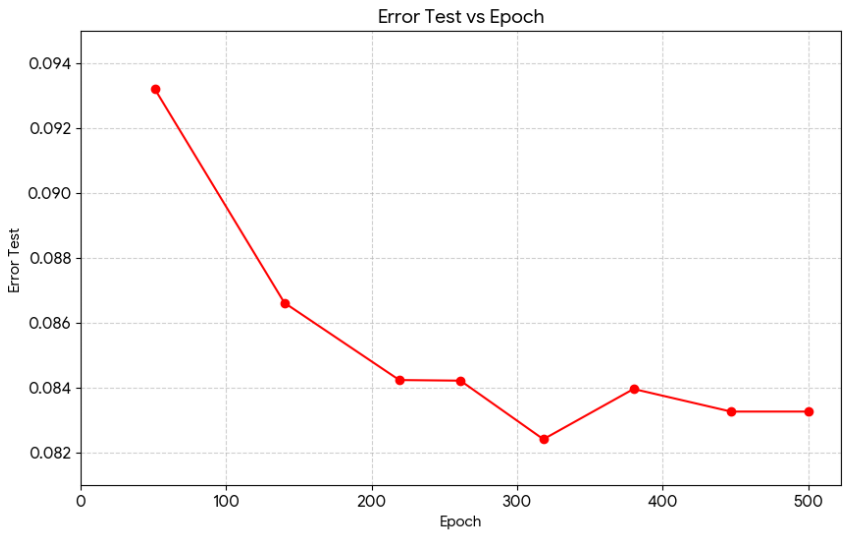

הגרף המשותף:

ניתוח תוצאות:

הגרף מציג את התקדמות שגיאות האימון והמבחן לאורך האיטרציות.
ניתן לראות כי שתי עקומות השגיאה – שגיאת האימון (קו ירוק כהה) ושגיאת המבחן (קו אדום מקווקו) – יורדות באופן עקבי ככל שמספר האיטרציות (Epochs) עולה. ירידה זו מעידה על כך שהמודל לומד ומשתפר בהדרגה.
למרות שמגמת הירידה משותפת לשתי העקומות, שגיאת האימון יורדת בקצב מעט מהיר יותר ומגיעה לערכים נמוכים יותר. פער קטן זה בין השגיאות עשוי להצביע על התחלה של למידת יתר (Overfitting), כאשר המודל מתאים את עצמו יותר לנתוני האימון.
עם זאת, העובדה שהפער נשאר יחסית קטן ושתי העקומות קרובות זו לזו, מצביעה על כך שהמודל שומר על איזון טוב בין למידה ליכולת הכללה לנתונים חדשים. בסך הכל, הגרף משקף תהליך אימון מוצלח עם התכנסות טובה של המודל.

סעיף ד + ה:

דוח מקרים חריגים:

נציג כמה מקרים חריגים מתוך מה שיצא:

שגיאה ראשונה:

```
Plot : weka.classifiers.meta.FilteredClas
Instance: 654
          gender : Female
             age : 82.0
    hypertension : 1.0
   heart_disease : 0.0
    ever_married : Yes
       work_type : Private
  Residence_type : Urban
avg_glucose_level : 62.46
             bmi : 20.3
  formerly smoked : 1.0
     never smoked : 0.0
          smokes : 0.0
prediction margin : -0.5717684363906859
 predicted stroke : 1
          stroke : 0
```

שגיאה שניה:

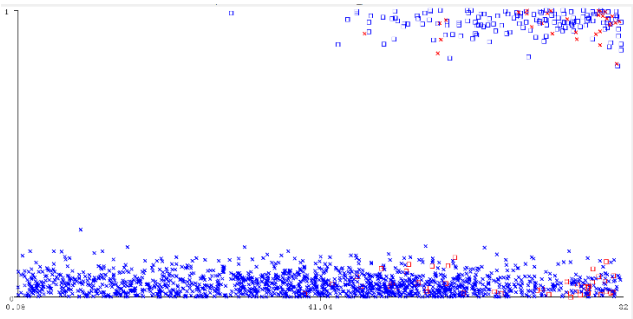

```
Plot : weka.classifiers.meta.FilteredClas
Instance: 1052
            gender : Female
               age : 39.0
      hypertension : 0.0
     heart_disease : 0.0
      ever_married : Yes
         work_type : Private
    Residence_type : Urban
avg_glucose_level : 254.95
               bmi : 35.5
   formerly smoked : 0.0
      never smoked : 0.0
            smokes : 1.0
prediction margin : -0.506033969005835
 predicted stroke : 1
            stroke : 0
```

שגיאה שלישית:

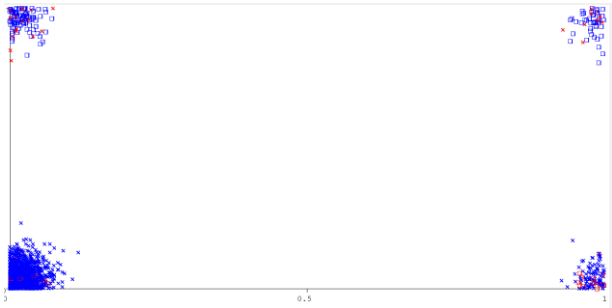

```
Plot : weka.classifiers.meta.FilteredClas
Instance: 571
            gender : Male
               age : 45.0
      hypertension : 1.0
     heart_disease : 0.0
      ever_married : Yes
         work_type : Private
    Residence_type : Urban
avg_glucose_level : 60.99
               bmi : 32.8
   formerly smoked : 0.0
      never smoked : 0.0
            smokes : 0.0
prediction margin : -0.18406040333275064
 predicted stroke : 1
            stroke : 0
```

שגיאה רביעית:

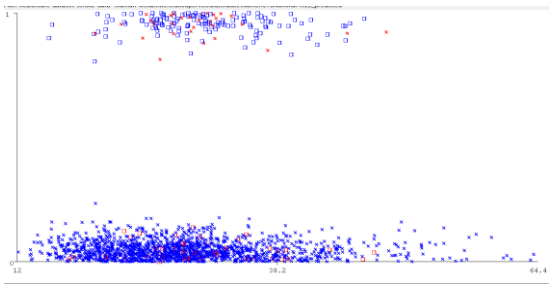

```
Plot : weka.classifiers.meta.FilteredClas
Instance: 1024
            gender : Female
               age : 61.0
      hypertension : 0.0
     heart_disease : 0.0
      ever_married : Yes
         work_type : Private
    Residence_type : Urban
avg_glucose_level : 129.31
               bmi : 41.2
   formerly smoked : 0.0
      never smoked : 0.0
            smokes : 0.0
prediction margin : -0.09477762797319589
 predicted stroke : 1
            stroke : 0
```

שגיאה חמישית:

```
Plot : weka.classifiers.meta.FilteredCla
Instance: 1052
            gender : Female
               age : 39.0
      hypertension : 0.0
     heart_disease : 0.0
      ever_married : Yes
         work_type : Private
    Residence_type : Urban
avg_glucose_level : 254.95
               bmi : 35.5
   formerly smoked : 0.0
      never smoked : 0.0
            smokes : 1.0
prediction margin : -0.506033969005835
 predicted stroke : 1
            stroke : 0
```

דווחנו כחמישה שגיאות של מקרים חריגים , נציג סיכום:

למרות מגמת השיפור הכללית, קיימים מקרים שבהם המודל ביצע סיווג שגוי. הדוגמאות שהוצגו לעיל ממחישות טעויות מסוג – False Positive מצבים שבהם המודל חזה שבץ (predicted stroke: 1) בעוד שבפועל סווג כלא היה שבץ (stroke: 0) טעויות אלו נובעות ממספר גורמים אפשריים:

- למידת יתר חלקית (Overfitting) : ייתכן שהרשת, למרות יכולת ההכללה הכללית, למדה בצורה הדוקה מדי דפוסים מסוימים בנתוני האימון, ומתקשה להכליל למקרים גבוליים או שונים במקצת בנתוני המבחן .
- חפיפת מאפיינים (Feature Overlap): ייתכנו מקרים בהם אנשים שלא חוו שבץ דומים מבחינת מאפיינים (כגון גיל, רמת סוכר, עישון) לאנשים שכן חוו שבץ, מה שמקשה על הרשת להבדיל ביניהם בצורה חד משמעית .דוגמאות המקרים החריגים מציגות שילוב של גורמי סיכון (כמו גיל מבוגר, יתר לחץ דם, רמת סוכר או BMI גבוהים, או היסטוריית עישון (גם אצל אלו שלא חוו שבץ בפועל .
- חוסר איזון בנתונים :(Data Imbalance) לפי הנתונים מחלקת ה Stroke=0-דומיננטית באופן ניכר בסט הנתונים . ומכך הדבר יכול לגרום להטיה של המודל לטובת המחלקה הגדולה יותר, ובמטרה לצמצם את פספוס מקרי השבץ ,(False Negatives) הוא עשוי לייצר יותר חיזויים חיוביים שגויים.(False Positives)
- רעש או נתונים חסרים: תהליכי עיבוד מקדים כמו טיפול בערכים חסרים, או טרנספורמציות של תכונות (כפי שבוצע), עלולים להכניס מידה מסוימת של "רעש" או להקשות על המודל לזהות קשרים עדינים בנתונים, מה שמוביל לטעויות.

לסיכום, רשת הנוירונים שהורצה בפרויקט הציגה ביצועים טובים ויכולת כללית לזהות את הדפוסים הרלוונטיים בנתונים ולהפחית את שיעור השגיאה לאורך זמן .הירידה בשגיאת האימון והמבחן והפער הקטן ביניהן מעידים על תהליך למידה מוצלח ויכולת הכללה סבירה.
עם זאת, ניתוח המקרים החריגים והבנת הגורמים לטעויות מדגישים את האתגרים הטמונים בבעיות סיווג רפואיות, במיוחד כאשר קיים חוסר איזון משמעותי בנתונים. שיעור השגיאה הנותר, למרות שאינו דרמטי, מצביע על כך שהמודל מתקשה להבחין בין מקרים גבוליים.
למסקנה על מנת לטפל אפשר לבצע:

- טיפול בחוסר איזון - יישום טכניקות ספציפיות כמו SMOTE לאיזון המחלקות בנתוני האימון.
- אופטימיזציה של פרמטרים וארכיטקטורה - ניסוי שיטתי של פרמטרים שונים ברשת (כגון קצב למידה, מספר נוירונים בשכבות חבויות, פונקציות הפעלה) ואף ארכיטקטורות רשת שונות.

שאלה 4:

הפרויקט עסק בחיזוי סיכון לשבץ מוחי באמצעות כריית מידע, שהחל בתהליך טיוב והכנת נתונים קפדנית, כולל טיפול בערכים חסרים, נרמול נתונים, וניסיון איזון עמדת הסיווג באמצעותSMOTE .
בממן 21 התמקדנו בהכנת נתונים ובבחירה והערכה של אלגוריתמי סיווג מבוססי עצי החלטה .שלבי טיוב הנתונים כללו טיפול בערכים חסרים בתכונות כמו (Gender מחיקת שורה BMI, השלמה לפי ממוצע ,Smoking_status- בינאריזציה, וכן Normalization, Discretization)בהשוואה בין עצי ההחלטה CART ו ,C4.5-שני המודלים הציגו ביצועים טובים, כאשר CART נבחר כעדיף במקצת בזיהוי חולי שבץ בפועל Sensitivity ו Accuracy-גבוהים יותר, מה שהופך אותו לבחירה מועדפת למטרות רפואיות.
בממן 22 הרחבנו את הפרויקט לכריית דפוסים, אשכול ורשתות נוירונים .אלגוריתם Apriori שימש לזיהוי חוקי קשר מיקוד הניתוח למקרים של stroke=1 בלבד לאחר סינון, הניב תובנות ממוקדות לגבי מאפייני סיכון, על אף כמות הנתונים המצומצמת .אלגוריתם K-Means אפשר לאשכול את הנתונים ולזהות פרופיל סיכון מובהק, המאופיין בגיל מבוגר ומחלות רקע .שיעור השגיאה באשכול (כ-29.93%) הצביע על מורכבות הבעיה וחפיפה בין הקבוצות .רשת נוירונים הראתה יכולת למידה והתכנסות טובה, עם ירידה עקבית בשגיאות האימון והמבחן ,אך ניתוח מקרים חריגים חשף False Positives המושפעים מחוסר איזון נתונים וחפיפת מאפיינים.
לסיכום, הפרויקט הדגים בהצלחה את הפוטנציאל של כריית מידע בחיזוי סיכון לשבץ מוחי, כאשר המודלים שפותחו סיפקו תובנות חשובות ויכולות סיווג יעילות. עם זאת, האתגרים הקיימים, בפרט חוסר האיזון הדומיננטי בנתונים וקיומם של מקרים גבוליים, דורשים התייחסות מתמשכת.
על מנת לשפר את אמינות ודיוק מודל החיזוי בעתיד, מומלץ להעמיק בטיפול בנתונים חסרים, לבצע הנדסת תכונות ממוקדת יותר (כמו חלוקת BMI לקטגוריות רפואיות או סיווג עישון),ליישם אסטרטגיות איזון נתונים מתקדמות יותר שילוב Oversampling ו ,Undersampling - ולבצע אופטימיזציה נוספת ושיטתית של פרמטרי המודלים השונים.

סוף פרוייקט – חלק 2!